

✓ KLASIFIKASI TEKS - ANALISA SENTIMEN TWITTER

Modul Lab ini berisi tutorial untuk melakukan analisa sentimen (positif, negatif, dan netral) dari data twitter(X).

Tahapan Proses Pembuatan Model Klasifikasi

1. Data Collecting
2. Preprocessing Data
3. Analyzing (Vectorization)
4. Build ML Model

Dataset digunakan pada Lab ini: https://drive.google.com/drive/folders/1cBdAV5IJOM3DnWQ-UH_xpcy0OtMQmWrK?usp=sharing

1. Data Collecting (Pengambilan Data)

Pada tahapan ini kita melakukan pengambilan data twitter dengan aplikasi apify. Apify aplikasi berbayar yang memiliki fasilitas free bersyarat. Pada percobaan ini kita akan mencoba mengambil tweet.

Data diupload ke Google Colab atau pun bisa diupload dulu ke dalam Drive masing-masing.

Note: dataset yang saya coba scrapping hanya mengandung 2 sentimen, positif dan netral saja

****Perlu dicoba untuk yang ada positif, netral dan negatif**

✓ 2. Preprocessing Data

✓ Load Data

```
# @title Load Data
import pandas as pd
```

```
df = pd.read_csv('/content/datatweetikn.csv', sep=';') # Changed the separator to semicolon
df.head()
```

	author/createdAt	author/id	author/name	text	Url	Label
0	Sun Mar 13 01:43:06 +0000 2022	1,50282E+23	Dokter Tifa	Lho! Jokowi bilang, belum ada listrik dan air ...	https://x.com/DokterTifa/status/18124471176776...	Negative
1	Sun Mar 13 01:43:06 +0000 2022	1,50282E+23	Dokter Tifa	Dia bakal ngomong pindah IKN ditunda, \nseente...	https://x.com/DokterTifa/status/18108212505474...	Negative
2	Fri May 04 19:36:50 +0000 2018	9,92488E+22	????????? ???????????	Heran banget, pada berkisah,\n\n?????: "Wiih.....	https://x.com/Naz_lira/status/1818712242340479228	Negative
3	Thu Jun 04 07:37:28 +0000 2009	44568999	mabuk rayuanmu	ISTANA PRESIDEN DI IKN\n\nTerlepas dari polemi...	https://x.com/ipunk_baik/status/18119661580750...	Netral
4	Thu Jun 11 07:25:44 +0000 2020	1,27098E+23	Comic3M	APBN ini Cuma sanggup bertahan 3 hari hidup di...	https://x.com/Tan_Mar3M/status/181900288119190...	Negative

✓ Separate Data from class

```
# @title Separate Data from class
X = df.drop('Label', axis=1)
y = df['Label']
print("data train:\n", X)
print("Label data train:\n",y)
```

```
data train:
      author/createdAt  author/id \
0  Sun Mar 13 01:43:06 +0000 2022  1,50282E+23
1  Sun Mar 13 01:43:06 +0000 2022  1,50282E+23
2  Fri May 04 19:36:50 +0000 2018  9,92488E+22
```

```

3  Thu Jun 04 07:37:28 +0000 2009      44568999
4  Thu Jun 11 07:25:44 +0000 2020  1,27098E+23
5  Fri Jun 09 18:13:21 +0000 2023  1,66723E+23
6  Sun Apr 18 11:54:43 +0000 2021  1,38375E+23
7  Thu Feb 07 03:23:08 +0000 2019  1,09335E+23
8  Sat Sep 19 10:11:23 +0000 2009      75519742
9  Sat Apr 06 09:13:11 +0000 2013  1331140639
10 Fri Jun 11 06:36:09 +0000 2010      154435354
11 Fri May 27 11:18:54 +0000 2022  1,53015E+23
12 Thu Aug 20 05:06:24 +0000 2020  1,29631E+23
13 Thu Sep 13 18:31:22 +0000 2018  1,04031E+23
14 Wed Oct 07 12:08:18 +0000 2009      80559922
15 Wed Aug 05 20:02:30 +0000 2020  1,2911E+22
16 Thu Nov 12 02:28:34 +0000 2020  1,32671E+23
17 Tue Aug 30 06:41:20 +0000 2022  1,5645E+22
18 Thu Feb 06 04:30:26 +0000 2020  1,22528E+23
19 Thu Dec 06 01:17:55 +0000 2012      992143328
20 Fri Sep 02 02:43:34 +0000 2022  1,56553E+23
21 Sun Jun 06 05:11:31 +0000 2021  1,40141E+23
22 Sat May 29 04:17:19 +0000 2021  1,39849E+23
23 Fri Feb 19 06:15:54 +0000 2010      115594670
24 Sun Dec 26 10:52:04 +0000 2010      230692266
25 Tue Mar 17 15:01:28 +0000 2009      24893875
26 Sun Mar 28 04:12:40 +0000 2021  1,37602E+23
27 Fri Nov 21 08:00:58 +0000 2014      2905814730
28 Mon Nov 08 16:53:55 +0000 2021  1,45775E+23
29 Sat May 18 08:59:07 +0000 2019  1,12967E+23
30 Sun Aug 23 12:27:25 +0000 2020  1,29751E+23
31 Tue Apr 16 03:17:01 +0000 2019  1,11799E+23
32 Wed Dec 02 09:44:11 +0000 2020  1,33407E+23

```

```

                                author/name \
0                                Dokter Tifa
1                                Dokter Tifa
2                                ???????? ?????????
3                                mabuk rayuanmu
4                                Comic3M
5                                @Topi_Merah
6                                bantoro_
7                                ?? KING TUKIJAN ??
8                                Nicho Silalahi
9                                ?????????????????
10                               Chusnul ch??timah
11                               ziii ??
12                               DEMOKRASI rasa NEPOTISME

```

```

13             Monica
14             ferizandra
15 Kuda Hitam! Jadilah Pemenang! Di Setiap Tantan...
16             Kominfo Kabupaten Katingan
17             Caca Marisa
18             Memeinaja
19             goh kok liang

```

✖ Penyebaran class

```

# @title Penyebaran class
y.value_counts()

```

	count
Negative	16
Positive	9
Netral	6

dtype: int64

✖ Case Folding text to lowercase

```

# @title Case Folding text to lowercase
X['text'] = X['text'].str.lower()
print(X['text'])

```

```

0    lho! jokowi bilang, belum ada listrik dan air ...
1    dia bakal ngomong pindah ikn ditunda, \nseente...
2    heran banget, pada berkisah,\n\n?????: "wiih....
3    istana presiden di ikn\n\nnterlepas dari polemi...
4    apbn ini cuma sanggup bertahan 3 hari hidup di...
5    situasi hari ini di istana ikn ( ini kiriman ...
6    inilah pik (pantai indah kapuk) yang dijadikan...
7    ditugaskan prabowo untuk mengawasi pembangunan...
8    kurang jahanam apa lagi rezim @jokowi ini ?\ng...
9    .\njkw gak mau ngantor di ikn karena air dan l...

```

```

10 sebulan yg lalu kata kalian, 2 bulan lagi ikn ...
11 yg bilang rakyat menderita, ya kalau rakyat yg...
12 nasib ikn semakin tidak jelas.....\nhgu 190 ta...
13 jika tidak bohong lagi nanti tgl 28 juli 2024,...
14 @mdy_asmara1701 dengan anggaran untuk ikn yang...
15 yakin pembangunan ikn tidak akan merusak alam ...
16 sobatkom! ayo dukung pembangunan ikn nusantara.
17 dukung terus pembangunan ikn nusantara yang ma...
18 kito dukung sanak bengkulu pembangunan ikn nus...
19 warga jawa timur dukung pembangunan smart city...
20 dukung pembangunan ikn nusantara\n- sumatera s...
21 dukung terus pembangunan ikn
22 pembangunan ikn picu pertumbuhan ekonomi\nt...
23 ini dekat lokasi ikn ga sih
24 #jokowi nanggung sih mestinya bukan #ikn tapi ...
25 orang2 ini sok tahu, sambil mengadu domba pak ...
26 bapak ini lucu, nyuruh orang lain tinggal di i...
27 ketika membangun ikn dibangun dengan awal pon...
28 btw ini kondisi jalan di sekitar ikn menuju is...
29 latar belakang ikn ada 3 salah satunya di biay...
30 saat dikatakan ali mochtar ngabalin akan pinda...
31 bisnis yg layak di ikn adalah jualan bakso htt...
32 banjir bandang di wilayah ikn penajam paser ut...
Name: text, dtype: object

```

✓ Cleansing Data

@title Cleansing Data

```
import re, string
```

```
def preprocess(text):
```

```

    text=text.strip() # menghapus whitespace characters include spaces, tabs, and newline char
    text= re.compile('<.*?>').sub('', text) # removes any HTML tags
    text = re.compile('[%s]' % re.escape(string.punctuation)).sub(' ', text) # removes all pur
    text = re.sub('\s+', ' ', text) # replaces multiple spaces with a single space
    text = re.sub(r'\[[0-9]*\]', ' ', text) # removes any text enclosed in square brackets (inc
    text= re.sub(r'[^w\s]', '', str(text).lower().strip()) # removes any characters that are
    text = re.sub(r'\d', ' ', text) # removes digits from the string
    text = re.sub(r'\s+', ' ', text) # replaces one or more whitespace characters with a single s
    return text

```

```
X['text']=X['text'].apply(lambda x:preprocess(x))
print(X['text'])
```

```
0    lho jokowi bilang belum ada listrik dan air di...
1    dia bakal ngomong pindah ikn ditunda seenteng ...
2    heran banget pada berkisah wiih ikn megah bang...
3    istana presiden di ikn terlepas dari polemik y...
4    apbn ini cuma sanggup bertahan hari hidup di i...
5    situasi hari ini di istana ikn ini kiriman lan...
6    inilah pik pantai indah kapuk yang dijadikan p...
7    ditugaskan prabowo untuk mengawasi pembangunan...
8    kurang jahanam apa lagi rezim jokowi ini gagal...
9    jkw gak mau ngantor di ikn karena air dan list...
10   sebulan yg lalu kata kalian bulan lagi ikn sdh...
11   yg bilang rakyat menderita ya kalau rakyat yg ...
12   nasib ikn semakin tidak jelas hgu tahun https ...
13   jika tidak bohong lagi nanti tgl juli ikn ista...
14   mdy asmara dengan anggaran untuk ikn yang ters...
15   yakin pembangunan ikn tidak akan merusak alam ...
16       sobatkom ayo dukung pembangunan ikn nusantara
17   dukung terus pembangunan ikn nusantara yang ma...
18   kito dukung sanak bengkulu pembangunan ikn nus...
19   warga jawa timur dukung pembangunan smart city...
20   dukung pembangunan ikn nusantara sumatera sela...
21       dukung terus pembangunan ikn
22   pembangunan ikn picu pertumbuhan ekonomi sumat...
23       ini deket lokasi ikn ga sih
24   jokowi nanggung sih mestinya bukan ikn tapi je...
25   orang ini sok tahu sambil mengadu domba pak pr...
26   bapak ini lucu nyuruh orang lain tinggal di ik...
27   ketika membangun ikn dibangun dengan awal pond...
28   btw ini kondisi jalan di sekitar ikn menuju is...
29   latar belakang ikn ada salah satunya di biayai...
30   saat dikatakan ali mochtar ngabalin akan pinda...
31   bisnis yg layak di ikn adalah jualan bakso htt...
32   banjir bandang di wilayah ikn penajam paser ut...
Name: text, dtype: object
```

✓ Tokenizing

```
# @title Tokenizing
import nltk
nltk.download('punkt')
from nltk.tokenize import word_tokenize
X['text'] = X['text'].apply(word_tokenize)
print(X['text'])
```

[nltk_data] Downloading package punkt to /root/nltk_data...

[nltk_data] Unzipping tokenizers/punkt.zip.

```
0      [lho, jokowi, bilang, belum, ada, listrik, dan...
1      [dia, bakal, ngomong, pindah, ikn, ditunda, se...
2      [heran, banget, pada, berkisah, wiih, ikn, meg...
3      [istana, presiden, di, ikn, terlepas, dari, po...
4      [apbn, ini, cuma, sanggup, bertahan, hari, hid...
5      [situasi, hari, ini, di, istana, ikn, ini, kir...
6      [inilah, pik, pantai, indah, kapuk, yang, dija...
7      [ditugaskan, prabowo, untuk, mengawasi, pemban...
8      [kurang, jahanam, apa, lagi, rezim, jokowi, in...
9      [jkw, gak, mau, ngantor, di, ikn, karena, air,...
10     [sebulan, yg, lalu, kata, kalian, bulan, lagi,...
11     [yg, bilang, rakyat, menderita, ya, kalau, rak...
12     [nasib, ikn, semakin, tidak, jelas, hgu, tahun...
13     [jika, tidak, bohong, lagi, nanti, tgl, juli, ...
14     [mdy, asmara, dengan, anggaran, untuk, ikn, ya...
15     [yakini, pembangunan, ikn, tidak, akan, merusak...
16     [sobatkom, ayo, dukung, pembangunan, ikn, nusa...
17     [dukung, terus, pembangunan, ikn, nusantara, y...
18     [kito, dukung, sanak, bengkulu, pembangunan, i...
19     [warga, jawa, timur, dukung, pembangunan, smar...
20     [dukung, pembangunan, ikn, nusantara, sumatera...
21     [dukung, terus, pembangunan, ikn]
22     [pembangunan, ikn, picu, pertumbuhan, ekonomi,...
23     [ini, deket, lokasi, ikn, ga, sih]
24     [jokowi, nanggung, sih, mestinya, bukan, ikn, ...
25     [orang, ini, sok, tahu, sambil, mengadu, domba...
26     [bapak, ini, lucu, nyuruh, orang, lain, tingga...
27     [ketika, membangun, ikn, dibangun, dengan, awa...
28     [btw, ini, kondisi, jalan, di, sekitar, ikn, m...
29     [latar, belakang, ikn, ada, salah, satunya, di...
30     [saat, dikatakan, ali, mochtar, ngabalin, akan...
31     [bisnis, yg, layak, di, ikn, adalah, jualan, b...
32     [banjir, bandang, di, wilayah, ikn, penajam, p...
```

Name: text, dtype: object

✓ Normalize Word

```
# @title Normalize Word
# Download data slang Indonesia di link https://github.com/louisowen6/NLP_bahasa_resources
# ambil yang combined_slang_words

def normalize_slang_words(text):
    slang_words = {"i":"saya","jt":"juta","@": "di", "abis": "habis", "ad": "ada", "adlh": "ac
    return [slang_words.get(word, word) for word in text]

X['text'] = X['text'].apply(normalize_slang_words)
print(X['text'])
```

```
0    [lho, jokowi, bilang, belum, ada, listrik, dan...
1    [dia, bakal, bicara, pindah, ikn, ditunda, see...
2    [heran, banget, pada, berkisah, wiih, ikn, meg...
3    [istana, presiden, di, ikn, terlepas, dari, po...
4    [apbn, ini, cuma, sanggup, bertahan, hari, hid...
5    [situasi, hari, ini, di, istana, ikn, ini, kir...
6    [inilah, pik, pantai, indah, kapuk, yang, dija...
7    [ditugaskan, prabowo, untuk, mengawasi, pemban...
8    [kurang, jahanam, apa, lagi, rezim, jokowi, in...
9    [jkw, gak, mau, ngantor, di, ikn, karena, air,...
10   [sebulan, yang, lalu, kata, kalian, bulan, lag...
11   [yang, bilang, rakyat, menderita, iya, kalau, ...
12   [nasib, ikn, semakin, tidak, jelas, hgu, tahun...
13   [jika, tidak, bohong, lagi, nanti, tanggal, ju...
14   [mdy, asmara, dengan, anggaran, untuk, ikn, ya...
15   [yakini, pembangunan, ikn, tidak, akan, merusak...
16   [sobatkom, ayo, dukung, pembangunan, ikn, nusa...
17   [dukung, terus, pembangunan, ikn, nusantara, y...
18   [kito, dukung, sanak, bengkulu, pembangunan, i...
19   [warga, jawa, timur, dukung, pembangunan, smar...
20   [dukung, pembangunan, ikn, nusantara, sumatera...
21   [dukung, terus, pembangunan, ikn]
22   [pembangunan, ikn, picu, pertumbuhan, ekonomi,...
23   [ini, deket, lokasi, ikn, ga, sih]
24   [jokowi, nanggung, sih, mestinya, bukan, ikn, ...
25   [orang, ini, sok, tahu, sambil, mengadu, domba...
```



```

26 [bapak, ini, lucu, nyuruh, orang, lain, tingga...
27 [ketika, membangun, ikn, dibangun, dengan, awa...
28 [ngomong-ngomong, ini, kondisi, jalan, di, sek...
29 [latar, belakang, ikn, ada, salah, satunya, di...
30 [saat, dikatakan, ali, mochtar, ngabalin, akan...
31 [bisnis, yang, layak, di, ikn, adalah, jualan,...
32 [banjir, bandang, di, wilayah, ikn, penajam, p...
Name: text, dtype: object

```

✓ Filtering (Stopword Removal)

```

# @title Filtering (Stopword Removal)
# https://github.com/louisowen6/NLP_bahasa_resources/blob/master/combined_stop_words.txt

stop_words = pd.read_csv('/content/combined_stop_words.txt', header=None).squeeze().tolist()

def remove_stopwords(words):
    return [word for word in words if word not in stop_words]

X['text'] = X['text'].apply(remove_stopwords)
print(X['text'])

```

```

0 [lho, jokowi, bilang, listrik, air, ikn, batal...
1 [bicara, pindah, ikn, ditunda, seenteng, bicar...
2 [heran, banget, berkisah, wihi, ikn, megah, ba...
3 [istana, presiden, ikn, terlepas, polemik, ter...
4 [apbn, sanggup, bertahan, ikn, https, t, co, o...
5 [situasi, istana, ikn, kiriman, dr, kawan, htt...
6 [pik, pantai, indah, kapuk, dijadikan, pesan, ...
7 [ditugaskan, prabowo, mengawasi, pembangunan, ...
8 [jahanam, rezim, jokowi, gagal, bawa, investor...
9 [jkw, gak, ngantor, ikn, air, listrik, anggota...
10 [sebulan, ikn, sdh, jakarta, bilang, pembangun...
11 [bilang, rakyat, menderita, iya, rakyat, malas...
12 [nasib, ikn, hgu, https, t, co, xh, xna, vxc]
13 [bohong, tanggal, juli, ikn, istana, kepreside...
14 [mdy, asmara, anggaran, ikn, tersisa, rp, tril...
15 [pembangunan, ikn, merusak, alam, proyek, iknu...
16 [sobatkom, ayo, dukung, pembangunan, ikn, nusa...
17 [dukung, pembangunan, ikn, nusantara, mantap, ...

```

```

18 [kito, dukung, sanak, bengkulu, pembangunan, i...
19 [warga, jawa, timur, dukung, pembangunan, smar...
20 [dukung, pembangunan, ikn, nusantara, sumatera...
21 [dukung, pembangunan, ikn]
22 [pembangunan, ikn, picu, pertumbuhan, ekonomi,...
23 [deket, lokasi, ikn, ga, sih]
24 [jokowi, tanggung, sih, mestinya, ikn, jembata...
25 [sok, mengadu, domba, prabowo, jokowi, ikn, is...
26 [lucu, nyuruh, ikn, emoh, ikn, https, t, co, z...
27 [membangun, ikn, dibangun, awal, pondasi, kebo...
28 [ngomong-ngomong, jalan, ikn, menuju, istana, ...
29 [latar, belakang, ikn, salah, satunya, biayai,...
30 [dikatakan, ali, mochtar, ngabalin, pindah, ik...
31 [bisnis, layak, ikn, jualan, bakso, https, t, ...
32 [banjir, bandang, wilayah, ikn, penajam, paser...
Name: text, dtype: object

```

✓ Stemming and Tagging

```
!pip install sastrawi
```

Requirement already satisfied: sastrawi in /usr/local/lib/python3.10/dist-packages (1.0.1)

```

from Sastrawi.Stemmer.StemmerFactory import StemmerFactory

factory = StemmerFactory()
i_stemmer = factory.create_stemmer()

def stemming(text):
    # Join the stemmed words back into a single string
    return ' '.join([i_stemmer.stem(word) for word in text])

X['text'] = X['text'].apply(stemming)
print(X['text'])

```

```

0    lho jokowi bilang listrik air ikn batal nganto...
1    bicara pindah ikn tunda enteng bicara gedung g...

```

```

2  heran banget kisah wihih ikn megah banget ber l...
3  istana presiden ikn lepas polemik kait bangun ...
4  apbn sanggup tahan ikn https t co omb imitasi xgj
5  situasi istana ikn kirim dr kawan https t co u...
6  pik pantai indah kapuk jadi pesan proyek strat...
7  tugas prabowo awas bangun ikn gibran tolak jok...
8  jahanam rezim jokowi gagal bawa investor ikn b...
9  jkw gak ngantor ikn air listrik anggar pln t p...
10 bulan ikn sdh jakarta bilang bangun infrastruk...
11 bilang rakyat derita iya rakyat malas derita n...
12         nasib ikn hgu https t co xh xna vxc
13 bohong tanggal juli ikn istana presiden nusant...
14 mdy asmara anggar ikn sisa rp triliun investor...
15         bangun ikn rusak alam proyek iknusantara
16         sobatkom ayo dukung bangun ikn nusantara
17 dukung bangun ikn nusantara mantap hebat ikn y...
18 kito dukung sanak bengkulu bangun ikn nusantar...
19 warga jawa timur dukung bangun smart city ikn ...
20 dukung bangun ikn nusantara sumatera selatan i...
21         dukung bangun ikn
22 bangun ikn picu tumbuh ekonomi sumatera barat ...
23         dekat lokasi ikn ga sih
24 jokowi nanggung sih mesti ikn jembatanselatsun...
25 sok adu domba prabowo jokowi ikn isu prabowo l...
26 lucu nyuruh ikn emoh ikn https t co zj wrjqpk1...
27 bangun ikn bangun awal pondasi bohong maka ikn...
28 ngomong-ngomong jalan ikn tuju istana negara h...
29 latar belakang ikn salah satu biaya utang cina...
30 kata ali mochtar ngabalin pindah ikn jawab gem...
31 bisnis layak ikn jual bakso https t co jkqigmpsn
32 banjir bandang wilayah ikn najam paser utara b...
Name: text, dtype: object

```

✓ Analyzing (Vectorization)

Karena keadaan data yang sedikit, maka data train dan data test adalah data yang sama. Jika data-nya banyak bisa menggunakan Split antara datatest dan datatrain menggunakan `train_test_split()`**bold text**

```
#Tf-Idf
```

```
from sklearn.feature_extraction.text import TfidfVectorizer
```

```

tfidf_vectorizer = TfidfVectorizer(use_idf=True)
tfidf_vectorizer_vectors = tfidf_vectorizer.fit_transform(X['text'])

# Create a dataframe from the sparse matrix
df = pd.DataFrame(tfidf_vectorizer_vectors.toarray(), columns=tfidf_vectorizer.get_feature_names())

# Print the dataframe
print(df)

```

	adu	ag	agenda	aguan	air	alam	ali \
0	0.000000	0.000000	0.000000	0.000000	0.317768	0.000000	0.000000
1	0.000000	0.000000	0.000000	0.000000	0.093813	0.000000	0.000000
2	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
3	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
4	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
5	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
6	0.000000	0.000000	0.000000	0.271054	0.000000	0.000000	0.000000
7	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
8	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
9	0.000000	0.000000	0.000000	0.000000	0.167314	0.000000	0.000000
10	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
11	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
12	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
13	0.000000	0.254613	0.000000	0.000000	0.000000	0.000000	0.000000
14	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
15	0.000000	0.000000	0.000000	0.000000	0.000000	0.494056	0.000000
16	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
17	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
18	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
19	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
20	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
21	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
22	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
23	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
24	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
25	0.079728	0.000000	0.039864	0.000000	0.000000	0.000000	0.000000
26	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
27	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
28	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
29	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
30	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.208536
31	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000

```

32  0.000000  0.000000  0.000000  0.000000  0.000000  0.000000  0.000000  0.000000

      ampas      anak      analisa  ...      wujud      wv      xgj      xh  \
0  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
1  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
2  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
3  0.000000  0.000000  0.223127  ...  0.000000  0.000000  0.000000  0.000000
4  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.407838  0.000000
5  0.000000  0.000000  0.000000  ...  0.000000  0.353733  0.000000  0.000000
6  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
7  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
8  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
9  0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
10 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
11 0.000000  0.170340  0.000000  ...  0.000000  0.000000  0.000000  0.000000
12 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.429822
13 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
14 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
15 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
16 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
17 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
18 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
19 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
20 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000
21 0.000000  0.000000  0.000000  ...  0.000000  0.000000  0.000000  0.000000

```

✓ Build Model Classification Naive Bayes

```
df=df.dropna()
```

```
y=y.dropna()
```

```

# Ensure that data and y have the same number of rows after dropping missing values
if df.shape[0] != y.shape[0]:
    # Find the minimum number of rows between data and y
    min_rows = min(df.shape[0], y.shape[0])

    # Truncate data and y to have the same number of rows

```

```
df = df.iloc[:min_rows]
y = y.iloc[:min_rows]

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(df, y, test_size=0.3, random_state=42)
print(X_train.index.size)
print(X_test.index.size)
```

```
21
10
```

✓ Split Train and Test Set (Pembagian Data)

```
# @title Split Train and Test Set (Pembagian Data)
# Validation Model using Hold Out Method
# contoh coding validation model: https://colab.research.google.com/drive/1xcaJU9vNzDd-6cwz9PJ
# 70% data training -30% data testing

from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(df, y, test_size=0.3, random_state=42)
print(X_train.index.size)
print(X_test.index.size)
```

```
21
10
```

✓ Naive Bayes (Modelling)

```
# @title Naive Bayes (Modelling)
# https://scikit-learn.org/stable/modules/naive\_bayes.html
from sklearn.naive_bayes import MultinomialNB
from sklearn.naive_bayes import BernoulliNB
from sklearn.naive_bayes import GaussianNB
```

```
from sklearn.naive_bayes import CategoricalNB
from sklearn.naive_bayes import ComplementNB
from sklearn.svm import SVC

import numpy as np
import matplotlib.pyplot as plt
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay

svm_classifier = SVC(kernel='linear')
# nb_tfidf = ComplementNB()
svm_classifier.fit(X_train, y_train)
#Predict y value for test dataset
y_predict = svm_classifier.predict(X_test)
```

Algoritma Naive Bayes pada library sklearn ada 5:

- Gaussian Naive Bayes: Cocok untuk data kontinu dengan distribusi normal. *Multinomial Naive Bayes: Cocok untuk data diskrit (count data).
- Bernoulli Naive Bayes: Cocok untuk fitur biner (keberadaan/kekurangan kata).
- Categorical Naive Bayes: Cocok untuk data kategorikal dengan lebih dari dua kategori.
- Complement Naive Bayes: Versi Multinomial Naive Bayes untuk kelas yang tidak seimbang.

✓ Naive Bayes (Evaluating Model)

```
# Menghitung confusion matrix dari class data testing dengan class hasil prediksi


cm = confusion_matrix(y_test, y_predict)

# Menampilkan confusion matrix
disp = ConfusionMatrixDisplay(confusion_matrix=cm, display_labels=svm_classifier.classes_)
```

```

disp.plot(cmap=plt.cm.Blues)
plt.title("Confusion Matrix")
plt.show()
# 0:netral, 1: positif

```



```

from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

```

```

# Menghitung metrik menggunakan library
accuracy = accuracy_score(y_test, y_predict)
precision = precision_score(y_test, y_predict, average='weighted')
recall = recall_score(y_test, y_predict, average='weighted') # https://scikit-learn.org/stable
f1 = f1_score(y_test, y_predict, average='weighted')

```



```
# Menampilkan hasil
print("Accuracy:", accuracy)
print("Precision:", precision)
print("Recall:", recall)
print("F1-Score:", f1)
```

```
Accuracy: 0.7
Precision: 0.7
Recall: 0.7
F1-Score: 0.6300000000000001
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1531: UndefinedMetricWarning: Precision is ill-defined and b
_warn_prf(average, modifier, f"{metric.capitalize()} is", len(result))
```

parameter **average** pada fungsi `precision_score`, `recall_score`, dan `f1_score` digunakan untuk menentukan bagaimana metrik dihitung ketika terdapat lebih dari dua kelas.

Berikut adalah perbedaannya:

- **micro**: Menghitung metrik secara global dengan menghitung total true positives, false negatives, dan false positives di semua kelas.
- **macro**: Menghitung metrik untuk setiap kelas secara independen, lalu mengambil rata-rata tanpa mempertimbangkan bobot.
- **weighted**: Menghitung metrik untuk setiap kelas secara independen, lalu mengambil rata-rata dengan mempertimbangkan bobot berdasarkan jumlah sampel di setiap kelas.
- **None**: Mengembalikan skor untuk setiap kelas tanpa mengambil rata-rata.

In this case, using a **weighted** average for precision, recall, and F1-score is the most suitable option.

Here's why: Your dataset has an uneven distribution of classes (as shown by `y.value_counts()`). The weighted average takes this imbalance into account. It calculates metrics for each class independently and then averages them, giving more weight to classes with more samples. This leads to a more representative evaluation of your model's performance, especially when dealing with imbalanced datasets.

✓ Predict the data test

```
# @title Predict the data test
```

```
new_tweet = "Ketika Membangun IKN dibangun dengan awal pondasi kebohongan"

# Case Folding text to lowercase
new_tweet = new_tweet.lower()
print(new_tweet)

# Cleansing the text
new_tweet=preprocess(new_tweet)
print(new_tweet)

# Tokenizing the text
new_tweet = word_tokenize(new_tweet)
print(new_tweet)

# Normalize the text
new_tweet = normalize_slang_words(new_tweet)
print(new_tweet)

# Stopword removal
new_tweet = remove_stopwords(new_tweet)
print(new_tweet)

# Stemming
new_tweet = stemming(new_tweet)
print(new_tweet)

# Vectorization
new_tweet = tfidf_vectorizer.transform([new_tweet])
print(new_tweet)
```

```
# Convert the sparse matrix to a dense matrix
new_tweet = new_tweet.toarray() # Convert to dense representation
```

```
# Predict the new tweet
prediction = svm_classifier.predict(new_tweet)
```

```
ketika membangun ikn dibangun dengan awal pondasi kebohongan
```

```
ketika membangun ikn dibangun dengan awal pondasi kebohongan
```

```
['ketika', 'membangun', 'ikn', 'dibangun', 'dengan', 'awal', 'pondasi', 'kebohongan']
```

```
['ketika', 'membangun', 'ikn', 'dibangun', 'dengan', 'awal', 'pondasi', 'kebohongan']
```

```
['membangun', 'ikn', 'dibangun', 'awal', 'pondasi', 'kebohongan']
```

```
bangun ikn bangun awal pondasi bohong
```

```
(0, 18)      0.4613894906264418
```

```
(0, 29)      0.534351335471724
```

```
(0, 50)      0.40181197539073665
```

```
(0, 123)     0.15132271402800568
```

```
(0, 300)     0.5632379256325429
```

```
['Negative']
```

```
/usr/local/lib/python3.10/dist-packages/sklearn/base.py:493: UserWarning: X does not have valid feature names, but SVC was fitted with
warnings.warn(
```